

TP 08: Modelo de claves Booleanas 1

Consigna 1:

Crea un programa en Python que permita al usuario realizar búsquedas booleanas (AND, OR, NOT) en un conjunto de documentos utilizando NLTK.

-Se tienen 5 documentos con información sobre inteligencia artificial y aprendizaje automático.

"doc1": "La inteligencia artificial está revolucionando la tecnología.",

"doc2": "El aprendizaje automático es clave en la inteligencia artificial.",

"doc3": "Procesamiento del lenguaje natural y redes neuronales.",

"doc4": "Las redes neuronales son fundamentales en deep learning.",

"doc5": "El futuro de la IA está en el aprendizaje profundo."

1)-Implementa una función que tokenice y limpie los documentos.

```
1 # Preprocesamiento: Tokenización y eliminación de stopwords
2 stop_words = set(stopwords.words('spanish'))
3
4 def preprocess(text):
5     tokens = word_tokenize(text.lower()) # Convertir a minúsculas y tokenizar
6     return set([word for word in tokens if word.isalnum() and word not in stop_words])
```

2) -Crea un índice invertido (asocia cada palabra clave a los documentos en los que aparece)

```
1 # Índice invertido (palabra clave → documentos donde aparece)
2 index = {}
3 for doc_id, text in documents.items():
4     words = preprocess(text)
5     for word in words:
6         if word not in index:
7             index[word] = set()
8             index[word].add(doc_id)
```

3) -Permite que el usuario ingrese una consulta booleana y devuelva los documentos relevantes.

Pruebas:

```
1 print("\nConsulta: inteligencia AND artificial")
2 print(boolean_search("inteligencia AND artificial")) # Debería devolver doc1, doc2, doc3
3
4 print("\nConsulta: redes OR aprendizaje")
5 print(boolean_search("redes OR aprendizaje")) # Debería devolver doc2, doc4
6
7 print("\nConsulta: inteligencia NOT automático")
8 print(boolean_search("inteligencia NOT automático")) # Debería devolver doc1, doc3
```

Resultados:

```
Consulta: inteligencia AND artificial
{'doc2', 'doc1'}

Consulta: redes OR aprendizaje
{'doc4', 'doc3', 'doc5', 'doc2'}

Consulta: inteligencia NOT automático
{'doc1'}
```