

TP 09: Modelo de claves Booleanas 2

Consigna 1:

Crea un programa en Python que permita al usuario realizar búsquedas booleanas (AND, OR, NOT) en un conjunto de documentos utilizando NLTK.

Se tienen 5 documentos con información sobre inteligencia artificial y aprendizaje automático.

"doc1": "Los egipcios construyeron las pirámides y desarrollaron una escritura jeroglífica.",


"doc2": "La civilización romana fue una de las más influyentes en la historia occidental.",

"doc3": "Los mayas eran expertos astrónomos y tenían un avanzado sistema de escritura.",

"doc4": "La antigua Grecia sentó las bases de la democracia y la filosofía moderna.",

"doc5": "Los sumerios inventaron la escritura cuneiforme y fundaron las primeras ciudades."

1)-Implementa una función que tokenice y limpie los documentos.



```
1 # Preprocesamiento: Tokenización y eliminación de stopwords
2 stop_words = set(stopwords.words('spanish'))
3
4 def preprocess(text):
5     tokens = word_tokenize(text.lower()) # Convertir a minúsculas y tokenizar
6     return set([word for word in tokens if word.isalnum() and word not in stop_words])
```

2) -Crea un índice invertido (asocia cada palabra clave a los documentos en los que aparece)

```
1 # Índice invertido (palabra clave → documentos donde aparece)
2 index = {}
3 for doc_id, text in documents.items():
4     words = preprocess(text)
5     for word in words:
6         if word not in index:
7             index[word] = set()
8             index[word].add(doc_id)
```

3) -Permite que el usuario ingrese una consulta booleana y devuelva los documentos relevantes.

Pruebas:

```
1 print("\nConsulta: egipcios AND pirámides")
2 print(boolean_search("egipcios AND pirámides")) # Debería devolver doc1
3
4 print("\nConsulta: escritura OR astrónomos")
5 print(boolean_search("escritura OR astrónomos")) # Debería devolver doc1, doc3, doc5
6
7 print("\nConsulta: romana NOT griegos")
8 print(boolean_search("romana NOT griegos")) # Debería devolver doc2
```

Resultados:

```
Consulta: egipcios AND pirámides  
{'doc1'}
```

```
Consulta: escritura OR astrónomos  
{'doc1', 'doc5', 'doc3'}
```

```
Consulta: romana NOT griegos  
{'doc2'}
```